

崑山科技大學
資訊工程系
碩士論文

LLM-ETF：基於大語言模型輔助之跨市場 ETF 趨勢預測與模
型比較研究

LLM-ETF: Large Language Model-Assisted ETF Trend
Prediction and Cross-Market Analysis

研究生：林子瑜

Student : Tzu-Yu Lin

指導教授：李冠榮

Advisor : Kuan-Rong Lee

Graduate School of Information Engineering

Kun Shan University

Tainan, Taiwan, R.O.C.

Thesis for Master of Science

June 2026

中華民國 115 年 6 月

崑山科技大學圖書資訊館

博碩士論文授權書

Kun Shan University Library and Information Center

Dissertation copyright license agreement

本授權書所授權之論文為本人在崑山科技大學 資訊工程 系所 _____ 組 _____ 學年度第 _____ 學期取得 _____ 士學位之論文。

This form attests that _____ Division at Department of _____ in Kun Shan University has received a _____ degree dissertation from me in the _____ semester of _____ academic year.

論文名稱：LLM-ETF：基於大語言模型輔助之跨市場 ETF 趨勢預測與模型比較研究

Dissertation title:

☒ 同意 (Agree) ☐ 不同意 (Disagree)

本人具有著作財產權之論文全文資料，授予教育部指定送繳之圖書館及本人畢業學校圖書館，為學術研究之目的以各種方法重製，或為上述目的再授權他人以各種方法重製，不限地域與時間，惟每人以一份為限。

上述授權內容均無須訂立讓與及授權契約書。依本授權之發行權為非專屬性發行權利。依本授權所為之收錄、重製、發行及學術研發利用均為無償。上述同意與不同意之欄位若未鉤選，本人同意視同授權。

The author of this dissertation gives the right of reproduction of the content of this dissertation for inclusion in the collection of the library assigned by Ministry of Education and Kun Shan University Library for the use of scholars and researchers as subject to copyright laws in force at the time of use. This permission is not time bound, but no person may make more than a single copy of the dissertation.

The agreement made above is non-transferable and non-exclusive. No payment has been received nor will be given for the rights of reproduction, distribution and storing the dissertation. The absence of choosing the agree-box or disagree-box in the above paragraphs shall be seen as consent given for the reproduction and distribution of the dissertation.

指導教授簽名(Chinese signature of major professor)：

(親筆正楷 Autograph in regular script)

研究生簽名(Chinese signature of graduate student)：

(親筆正楷 Autograph in regular script)

學號(Student ID number)：

(務必填寫 Required field)

日期：中華民國 115 年 6 月 日

Date of signature：(YYYY/MM/DD)

LLM-ETF：基於大語言模型輔助之跨市場 ETF 趨勢預測與模型比較研究

林子瑜*

李冠榮**

*崑山科技大學資訊工程研究所 研究生

**崑山科技大學資訊工程系 副教授

摘 要

投資人進行跨市場 ETF 交易時,常面臨資訊不對稱與缺乏直觀比較工具之問題。本研究提出一個以大語言模型輔助之趨勢分析框架,系統性比較統計、機器學習、深度學習與大語言模型四個世代之預測模型,並實作名為 LLM-ETF 之互動式視覺化平台;該平台整合表現最佳之預測模型與 GPT 輔助模組,提供風險摘要與白話解讀,支援台股與美股之並排比較。

本研究分為兩大主軸。第一主軸為跨世代模型之效能比較,使用 SPY、QQQ 與 0050.TW 之日交易資料,於「次日漲跌分類」與「次日收盤價迴歸」兩種任務上,系統性比較統計模型 (ARIMA)、機器學習集成模型 (隨機森林、XGBoost、AdaBoost、Gradient Boosting)、深度學習模型 (單層與雙層 LSTM) 以及大語言模型 (OpenAI GPT 系列) 之表現。第二主軸為視覺化平台實作,將模型整合至以 Streamlit 開發之 LLM-ETF 平台,並導入 GPT 模組提供風險摘要與白話解讀。

實驗結果顯示,於迴歸任務中,三個市場之模型排序一致——以可跨市場比較之平均絕對百分比誤差 (MAPE) 衡量,ARIMA (0.79% - 1.04%) 優於 LSTM (2.14% - 3.73%) 優於集成樹模型 (8.44% - 11.88%),顯示在價格預測上較簡單之統計模型反而較複雜模型穩定;集成模型因無法外推超出訓練範圍之新高價,於長期上漲之測試期誤差最大。於分類任務中,各模型之 F1-score 多貼近「全部預

測上漲」之基準（Always-Up，0.736），最佳者為隨機森林（0.732）與單層 LSTM（0.694），顯示分類高分主要來自多頭市場之上漲偏態。本研究另以 GPT-4o-mini 進行小樣本數值迴歸探索，三個市場之決定係數（ R^2 ）皆達約 0.80，顯示大語言模型於數值預測上之潛力。平台端對端平均延遲低於 1 秒。

本研究主要貢獻有三：第一，建立涵蓋統計、機器學習、深度學習與大語言模型之跨世代、雙任務比較基準；第二，揭露台股 0050.TW 之預測難度高於美股，並指出集成模型無法外推之結構性限制；第三，實作具教學意圖之開源 LLM 輔助平台，降低非專業使用者之資訊門檻。

*作者

**指導教授

關鍵詞：ETF、大語言模型、長短期記憶網路、隨機森林、視覺化平台、跨市場比較、ARIMA、迴歸預測、梯度提升、平均絕對百分比誤差

LLM-ETF: Large Language Model-Assisted ETF Trend Prediction and Cross-Market Analysis

Tzu-Yu Lin*

Kuan-Rong Lee **

Department of Information Engineering

Kun Shan University

Abstract

Investors engaging in cross-market ETF trading often face information asymmetry and a lack of intuitive comparison tools. This study proposes a large language model (LLM)-assisted trend-analysis framework that systematically compares four generations of predictive models—statistical, machine-learning, deep-learning, and large-language models—and implements an interactive visualization platform named LLM-ETF. The platform integrates the best-performing predictive model together with a GPT module that generates risk summaries and plain-language interpretations to support side-by-side comparison of the Taiwanese and U.S. markets.

The research is organized into two thrusts. The first is a cross-generational model comparison conducted on the daily trading data of U.S. ETFs (SPY, QQQ) and a Taiwanese ETF (0050.TW), in which every model is evaluated on two tasks: next-day directional classification and next-day closing-price regression. Statistical models (ARIMA), machine-learning ensembles (Random Forest, XGBoost, AdaBoost, and Gradient Boosting), deep-learning models (single- and double-layer LSTM), and large language models (the OpenAI GPT series) are compared. The second thrust is the implementation of the visualization platform, built with Streamlit and augmented by an OpenAI GPT module.

Experimental results reveal a consistent model ordering across all three markets in the regression task: measured by the scale-free, cross-market mean absolute percentage error (MAPE), ARIMA(0.79%–1.04%) outperforms LSTM (2.14%–3.73%), which in turn outperforms the tree ensembles (8.44%–11.88%). This indicates that, for price prediction, simpler statistical models can be more stable than more complex ones; the ensembles incur the largest error because they cannot extrapolate beyond the price range seen during training and therefore flatten out over the persistently rising test period. In the classification task, the F1-scores of all models cluster near the Always-Up baseline (0.736)—the best being Random Forest (0.732) and single-layer LSTM (0.694)—suggesting that the seemingly high scores stem mainly from the upward bias of a bull market rather


than from genuine directional skill. A further small-sample regression experiment with GPT-4o-mini attains a coefficient of determination (R^2) of about 0.80 across all three markets, demonstrating the potential of LLMs in numerical prediction. The platform's end-to-end latency is below one second.

The main contributions of this study are threefold: (1) establishing a cross-generational, dual-task benchmark spanning statistical, machine-learning, deep-learning, and large-language models; (2) revealing that the Taiwanese ETF (0050.TW) is significantly harder to predict than its U.S. counterparts, and identifying the structural inability of ensemble models to extrapolate; and (3) implementing an open-source, education-oriented LLM-assisted platform that lowers the information barrier for non-expert users.

*Author :

**Advisor :

Keywords: ETF, large language model, ARIMA, Long Short-Term Memory, Random Forest, gradient boosting, regression prediction, mean absolute percentage error, visualization platform, cross-market comparison



誌 謝

本論文得以完成，首先感謝指導教授李冠榮老師。在碩士研究期間，承蒙老師的指導與支持，讓我得以順利完成這份研究，在此致上誠摯的謝意。

此外，要特別感謝曾龍老師。在修習老師課程的過程中，我學到了許多紮實的觀念與方法，讓我能將課堂所學實際運用於本研究之中；研究期間遇到問題時，老師也時常不吝給予建議與討論，使我獲益良多。

也感謝王文彥主任與蔡仁勝老師撥冗擔任口試委員，提供諸多寶貴的意見，使本論文更臻完整。並感謝研究所期間授課的各位老師，在我對研究方向感到困惑時，耐心與我討論、推薦相關文獻，給予我許多啟發。

最後，我要感謝我的家人。重返校園、從學士一路念到碩士，完整地走過這六年並不容易，謝謝你們從不質疑、始終支持，成為我最穩固的後盾，讓我能安心完成學業。也謝謝這一路上遇到的每一位師長與同學，因為有你們的支持與幫助，我才能順利走到今天。



林子瑜 謹誌於崑山科技大學

目 錄

摘 要	II
Abstract	IV
誌 謝	VI
目 錄	VII
圖 表 目 錄.....	IX
第一章 緒論.....	10
1.1 研究背景.....	10
1.2 研究動機.....	10
1.3 研究目的與問題	11
1.4 研究範圍與限制	12
1.4.1 研究範圍.....	12
1.4.2 研究流程.....	13
1.4.3 關注要點.....	14
第二章 文獻探討	14
2.1 金融時間序列預測之基礎理論	14
2.2 機器學習與深度學習於股價預測之應用.....	15
2.3 大語言模型於金融輔助決策之潛力	17
2.4 輔助型平台設計	17
第三章 研究設計與方法	18
3.1 研究架構與實驗流程.....	18
3.2 資料來源與前處理	20
3.2.1 資料蒐集.....	20
3.2.2 資料清洗與時間對齊.....	20
3.2.3 特徵工程.....	21
3.2.4 目標變數（標籤）	23
3.2.5 數據標準化	24
3.3 預測模型介紹	25
3.3.1 統計基準模型（ARIMA）	25
3.3.2 隨機森林（Random Forest）	25
3.3.3 其他集成模型（XGBoost、AdaBoost、Gradient Boosting）	26
3.3.4 單層 LSTM（Single-Layer LSTM）	26
3.3.5 雙層 LSTM（Double-Layer Stacked LSTM）	27
3.3.6 單向 LSTM（Unidirectional LSTM）	28
3.3.7 雙向 LSTM（Bidirectional LSTM）	29

3.4 模型訓練與評估方法.....	29
3.5 LLM-ETF 系統架構及效能測試	32
第四章 研究成果與分析	35
4.1 模型效能比較	35
4.2 迴歸任務效能比較	37
4.3 大語言模型輔助實驗.....	40
第五章 結論與建議	42
5.1 研究結論.....	42
研究問題回應	42
5.2 研究建議.....	43
5.3 未來研究方向	45
全文總結	47
參考文獻.....	48



圖 表 目 錄

圖 3-1 系統整體架構圖.....	19
圖 3-2 雙層 LSTM 模型架構圖.....	28
表 3-1 各模型超參數設定.....	30
圖 4-2:三市場各模型族之測試集 MAPE 比較(數值越低越佳).....	39
表 4-1：各模型於 SPY 市場之分類效能.....	35
表 4-2：QQQ 與 0050.TW 市場之分類效能.....	36
表 4-3：各模型迴歸測試集 MSE.....	38
表 4-4：各模型迴歸測試集 MAPE (%).....	38
表 4-5 GPT-3.5 分類任務結果 (SPY, 200 樣本).....	40
表 4-6 GPT-4o-mini 迴歸任務結果 (小樣本, 各 50 筆).....	41

第一章 緒論

本章首先說明研究背景與動機，接著提出研究目的與問題，界定研究範圍與限制，最後說明論文整體架構與研究流程。

1.1 研究背景

指數股票型基金（Exchange Traded Fund, ETF）近年已成為全球投資人廣泛使用之金融工具。根據 ETFGI（2024）發布之統計，截至 2024 年底，全球 ETF 資產管理規模已突破 12 兆美元（ETFGI, 2024）。ETF 具備交易便利、成本低廉、透明度高特性，為散戶與機構投資人進行資產配置之重要選項。

在台灣，ETF 市場同樣快速成長。市值型 ETF 如元大台灣 50（0050.TW）追蹤台灣 50 指數，高股息 ETF 如 0056、00878 亦深受投資人青睞。與此同時，美國股市（以 SPY 追蹤 S&P 500 指數、QQQ 追蹤 Nasdaq-100 指數為代表）亦吸引大量台灣投資人關注。然而，跨市場投資常伴隨資訊不對稱問題，投資人對美國市場之熟悉程度遠低於本地市場，導致決策時產生猶豫或誤判。

1.2 研究動機

本研究之動機可歸納為以下三個面向。

第一，跨市場比較工具之缺乏。市面上多數財經網站提供股價查詢與技術指標，但通常呈現大量未經整理之原始數據，且缺乏同時比較台股與美股走勢之簡易工具。多數工具僅呈現歷史走勢，無法對未來短期趨勢提供參考，增加非專業使用者之決策困難。

第二，機器學習預測之黑箱問題。人工智慧技術之發展為金融預測帶來新可

能，機器學習模型能從歷史數據中學習潛在模式並預測未來走勢。然而，一般投資人對 AI 模型常抱持「黑箱」疑慮，僅看到預測結果卻不理解判斷依據，此不信任感降低其使用 AI 輔助決策之意願。

第三，大語言模型於金融輔助決策之潛力。近期大語言模型（Large Language Model, LLM），如 GPT 系列、Gemini 等，在文本理解與生成任務上展現強大能力。初步研究已將 LLM 應用於情緒分析、新聞解讀與財務報告摘要，但在 ETF 趨勢預測上仍屬少見。本研究嘗試將 LLM 作為輔助模組，提供市場風險摘要與預測結果之白話解讀，以降低使用者對 AI 模型之不信任感，並探索 LLM 在跨市場比較中的輔助價值。

1.3 研究目的與問題

基於上述動機，本研究設定以下研究目的：

1. 跨世代模型效能比較:比較統計(ARIMA)、機器學習集成(隨機森林、XGBoost、AdaBoost、Gradient Boosting)、深度學習(單／雙層 LSTM)與大語言模型(GPT)在 ETF 次日漲跌「分類」與次日收盤價「迴歸」兩任務上之效能。
2. 跨市場分析:分析同一模型在美國與台灣市場之表現差異,探討可預測性之本質落差。
3. 互動式視覺化平台與 LLM 輔助模組:實作以 Streamlit 為基礎之平台,整合 GPT 輔助模組提供風險摘要,支援台股與美股並排比較。

對應上述目的，本研究提出以下研究問題（Research Questions, RQs）：

- RQ1:統計(ARIMA)、機器學習集成(隨機森林、XGBoost、AdaBoost、Gradient Boosting)、深度學習(單／雙層 LSTM)與大語言模型(GPT),於漲跌分類與收盤價迴歸兩任務之效能優劣為何？
- RQ2:同一模型在台股 0050.TW 之效能是否顯著低於美股 SPY/QQQ？此

差異是否反映市場可預測性之本質差異？

- RQ3:分類採 F1、迴歸採 MAPE/RMSE/R² 時,模型排序與結論是否一致？
- RQ4:以大語言模型輔助之視覺化平台,能否幫助非專業使用者理解 AI 預測之結果與限制？

1.4 研究範圍與限制

1.4.1 研究範圍

本研究專注於三大模型類別之比較分析：機器學習、深度學習與大語言模型。各類別之代表模型說明如下。

1. 統計模型:以 ARIMA 為迴歸任務之基準模型(Baseline)。
2. 機器學習模型:以四種集成樹模型為代表(隨機森林、XGBoost、AdaBoost、Gradient Boosting)。
3. 深度學習模型：以長短期記憶網路（Long Short-Term Memory, LSTM）及其變體（及其變體(單層 LSTM、雙層 LSTM、單層雙向 LSTM、雙層雙向 LSTM)）為代表。LSTM 能有效捕捉時間序列之長期依賴關係，適合處理股價這類具有時間關聯性之數據。
4. 大語言模型：以 OpenAI GPT 系列為主要輔助模組，另於文獻中討論 Google Gemini 之相關研究與差異。本研究之大語言模型定位為輔助分析工具，提供風險摘要與市場解讀，不作為主要預測引擎。
5. 評估指標：本研究同時進行分類與迴歸兩任務。分類任務採 F1-score 為主要指標(精確率與召回率之調和平均,於類別不平衡資料較準確率更真實);迴歸任務採 MAPE(可跨市場比較)為主,輔以 MSE、RMSE、MAE 與 R²。
6. 資料與期間：本研究專注於技術面數據（開盤價、最高價、最低價、收盤價、成交量），未納入總體經濟指標或新聞情緒等基本因素。資料期間為 2016 年 1 月至 2026 年 1 月,約 10 年之日交易資料。研究標的涵蓋美國市

場 ETF (SPY、QQQ) 與台灣市場 ETF (0050.TW)。

後續研究可擴展方向：後續研究可納入總體經濟指標（如利率、GDP）、新聞情緒分析、社群媒體輿情等基本面或消息面因素；亦可延伸至盤中即時預測、高頻交易或不同市場（如新興市場）之比較。

1.4.2 研究流程

本研究依循以下主要步驟進行：

1. 問題定義與文獻蒐集：確認研究問題，回顧金融時間序列預測、機器學習、深度學習及大語言模型之相關文獻。
2. 資料蒐集與前處理：透過 Yahoo Finance API 下載 SPY、QQQ 與 0050.TW 之歷史日線資料，進行清洗、時間對齊與缺失值處理。
3. 特徵工程:依任務計算不同特徵——分類採 Return、MA20、MA60、RSI;迴歸採落後價(Lag1/2/5)、MA10、MA50、波動率。
4. 模型訓練與比較:訓練 ARIMA、四種集成樹模型、單／雙層 LSTM 與 GPT,於分類與迴歸兩任務比較效能;迴歸統一採 TimeSeriesSplit 五折交叉驗證。
5. 跨市場分析：比較同一模型在美股與台股上之表現差異，探討可預測性落差及其可能原因。
6. 平台實作：將最佳預測模型整合至 Streamlit 開發之互動式視覺化平台，導入 GPT 輔助摘要模組，提供風險提示與市場解讀。
7. 系統測試與案例驗證：進行平台效能測試（延遲、回應速度）及案例驗證（如俄烏戰爭期間之風險摘要合理性）。
8. 結論與建議：歸納研究成果，提出學術與實務貢獻，並說明研究限制與未來方向。

1.4.3 關注要點

本研究專注於以下三個核心問題之探討：

1. 模型效能比較:統計、機器學習、深度學習與大語言模型四個世代,在分類與迴歸兩任務之效能差異為何?複雜模型是否真優於簡單模型?
2. 跨市場可預測性差異：同一預測模型在台股 0050.TW 上之效能是否顯著低於其在美股 SPY 上之效能？此差異是否與市場結構、流動性或資訊傳播效率有關？
3. LLM 輔助平台之可行性：以大語言模型輔助之視覺化平台，能否透過並排比較與簡潔圖表設計，幫助非專業使用者理解 AI 預測之結果與限制？GPT 生成之風險摘要是否與市場實際走勢邏輯一致？

第二章 文獻探討

本章回顧金融時間序列預測的相關理論、機器學習模型的發展，以及視覺化平台的設計原則，作為本研究模型選擇與系統設計的理論基礎。

2.1 金融時間序列預測之基礎理論

近年研究指出，金融市場並非完全有效，其價格變動理論主要可分為以下幾種觀點：

效率市場假說（Efficient Market Hypothesis）：認為在一個資訊充分流通的市場中，資產價格已反映所有已知資訊，因此無法透過任何分析方法獲得超額報酬 (Fama, 1970)。

隨機漫步理論（Random Walk Theory）：主張股價變動無法由過去行為推

測，是隨機且不可預測的 (Malkiel, 1973)。

行為財務學 (Behavioral Finance)：發現投資人存在過度反應、處置效應等非理性行為，導致價格偏離其基本價值 (Shiller, 2015)。

適應性市場假說 (Adaptive Markets Hypothesis)：整合效率市場與行為財務之觀點，認為市場效率會隨環境與參與者行為而改變，預測模型之效能也將隨之波動 (Lo, 2017)。

在統計模型方面,ARIMA(自迴歸整合移動平均)為時間序列預測中最具代表性之方法,由自迴歸項(AR, p)、差分項(I, d)與移動平均項(MA, q)組成。其中差分項透過 d 次差分消除趨勢與單位根,使非定態序列趨於定態;此特性使 ARIMA 在預測具明顯趨勢之股價序列時,能跟隨價格水準之變動。相較於需大量資料與調參之深度模型,ARIMA 結構簡潔、可解釋性高,常作為衡量複雜模型增益之基準。本研究即以 ARIMA 作為迴歸任務之基準模型,檢驗深度學習與集成模型是否真能帶來顯著提升。

除上述理論學派外，技術分析領域發展出多種常用指標，用以輔助價格趨勢判斷。常見指標可分為三大類：趨勢類指標如移動平均線 (MA)、指數平滑異同移動平均線 (MACD)，用以辨識股價方向；動能類指標如相對強弱指標 (RSI)、隨機指標 (KD)，用以衡量漲跌強度與超買超賣狀態；波動類指標如布林通道 (Bollinger Bands)、歷史波動率 (Volatility)，用以評估市場風險。本研究在後續特徵工程中選用 MA20、MA60、RSI 與年化波動率，即涵蓋此三類指標之代表性項目。

2.2 機器學習與深度學習於股價預測之應用

1. 機器學習模型應用：

集成學習 (Ensemble Learning)：隨機森林 (Random Forest) 利用多棵決策樹的投票機制提升穩定性 (Breiman, 2001)。

進階樹模型:除隨機森林(Bagging)外,Boosting 系列模型亦廣泛應用於金融預測。AdaBoost 透過提高錯分樣本權重逐步修正;Gradient Boosting 沿損失函數梯度方向擬合殘差;XGBoost 則於其上加入正規化與二階梯度近似,兼顧精度與效率。本研究納入此四種集成模型進行比較。

2. 深度學習與 LSTM 實證研究：

Krauss et al. (2017)：在 S&P 500 成分股的預測研究中，明確比較了 深度神經網路 (Deep Neural Networks)、梯度提升樹 (Gradient-Boosted Trees) 與隨機森林 (Random Forests) 等模型的效能，發現這幾種方法皆能有效捕捉市場的短期動能。

LSTM 相關實證：長短期記憶網路 (LSTM) 已被證實在金融時間序列預測中優於傳統模型。Fischer & Krauss (2018) 的經典研究指出，LSTM 能成功辨識市場異常現象並處理高雜訊數據，回測績效優於傳統機器學習模型。在台灣市場方面，林子哲 (2024) 的研究證實了 LSTM 家族模型在台股價格預測上的有效性。

3. LSTM 變體架構的應用：

雙層堆疊 LSTM (Stacked LSTM)：透過增加網路的深度，讓模型能提取更高層次、更抽象的特徵，在語音識別與股價預測等任務中，其表現優於單層 LSTM。

雙向 LSTM (Bidirectional LSTM)：透過正向與反向兩個隱藏層來捕捉完整的序列脈絡。Qiu et al. (2020) 的研究將其應用於股價趨勢預測，結果顯示雙向架構在波動劇烈的市場中可能表現更佳。

除 LSTM 及其變體外，近年深度學習在金融預測上亦出現其他發展方向。例如，門控循環單元 (GRU) 為 LSTM 之簡化版本，參數較少、訓練更快，在部分研究中表現與 LSTM 相近；Transformer 模型 憑藉自注意力機制，能捕捉極長序列之依賴關係，已應用於股價趨勢預測；混合模型 如 CNN-LSTM 結合卷積網路之特徵提取能力與 LSTM 之時序記憶能力，亦取得不錯效果。本研究以 LSTM 家族為主要深度學習模型，上述方向可作為後續延伸研究之參考。

徐維延(2019)以集成模型預測台股加權指數,發現樹模型受外推限制,難以預測超出訓練範圍之新高價。吳冠霆(2025)比較跨市場指數,發現 ARIMA 於 MAPE 等指標上優於 LSTM。此二者分別呼應本研究中集成模型「預測躺平」與 ARIMA 表現最佳之發現。

2.3 大語言模型於金融輔助決策之潛力

近年大語言模型 (Large Language Model, LLM) 如 GPT 系列、Gemini 等在自然語言處理任務上展現強大能力。金融領域之初步研究已將 LLM 應用於情緒分析、新聞解讀與財務報告摘要。佛羅里達大學之研究顯示, LLM 在股票價格預測上表現出潛力, 但其準確性高度依賴市場狀況。另一篇發表於 ICBEM 2025 之論文明確指出, LLM 對股價變動方向之預測仍面臨挑戰, 難以達到理想之準確率。綜合而言, LLM 在結構化數值預測上尚無法取代專門設計之時序模型, 但其在非結構化文本分析與輔助解釋上具有獨特價值。本研究將 LLM 定位為輔助模組, 用於生成風險摘要與預測結果之白話解讀, 而非作為主要預測引擎。

2.4 輔助型平台設計

為使模型預測結果更易於判讀與比較, 本研究建置一互動式輔助平台。該平台參考 Few (2013)之儀表板設計原則, 力求以清晰、直觀之視覺化圖表呈現漲跌機率與技術指標。如同葉國毅 (2024) 在其研究所述, 此類平台能有效降低非專業使用者之資訊負擔。因此, 本平台亦整合台股與美股之預測結果, 並排顯示, 以利使用者直觀比較兩市場之模型表現, 輔助其理解跨市場預測之差異。

第三章 研究設計與方法

本章說明本研究之資料來源、前處理流程、預測模型架構、訓練評估方式，以及視覺化平台之系統設計。全章分為兩大主題：第一主題為模型效能比較，第二主題為視覺化平台實作。

3.1 研究架構與實驗流程

本研究分為兩大主題。第一主題為模型效能比較：使用 2016 年 1 月至 2026 年 1 月間 SPY、QQQ 與 0050.TW 之日交易資料,於「次日漲跌分類」與「次日收盤價迴歸」兩任務上,比較 ARIMA、四種集成樹模型(隨機森林、XGBoost、AdaBoost、Gradient Boosting)、單／雙層 LSTM 與大語言模型 (GPT)之效能。預期台股 0050.TW 之預測難度高於美股,且不同世代模型在兩任務上各有優劣。

第二主題為視覺化平台實作：將第一主題中表現最佳之預測模型整合至以 Streamlit 開發之互動式平台，並導入 OpenAI GPT 模組，提供即時漲跌機率、技術指標圖表及風險摘要，支援台股與美股之並排比較。

整體研究流程如圖 3-1 所示，依序為：

資料蒐集：透過 Yahoo Finance API 下載 OHLCV 歷史資料（Open, High, Low, Close, Volume）。

資料清洗與時間對齊：解決美股與台股交易日不一致問題，並以 SQLite 儲存。

特徵工程：依任務計算不同特徵;分類採 StandardScaler、LSTM 迴歸採 MinMax、樹迴歸不縮放。

模型訓練:訓練 ARIMA、集成樹模型(隨機森林、XGBoost、AdaBoost、Gradient Boosting)、單／雙層 LSTM 與 GPT,進行分類與迴歸兩任務。


模型評估：迴歸採 TimeSeriesSplit 五折;分類採 80/20 順序切分。

平台實作：以 Streamlit 開發前端，載入最佳模型提供即時預測，並整合 GPT 生成風險摘要。

效能測試與案例驗證：記錄平台回應速度，並以俄烏戰爭期間資料驗證 GPT 摘要之合理性。

以上流程對應第四章之實驗結果與分析。

圖 3-1 系統整體架構圖



3.2 資料來源與前處理

3.2.1 資料蒐集

本研究選取三檔具代表性的 ETF 作為研究標的，分別涵蓋美國整體市場、美國科技股市場與台灣整體市場：

SPY (SPDR S&P 500 ETF Trust)：追蹤美國 S&P 500 指數，成份股為美國 500 家大型上市公司，涵蓋約 80% 的美國股市市值，被廣泛視為美國整體市場的基準。

QQQ (Invesco QQQ Trust)：追蹤 Nasdaq-100 指數，成份股以美國科技股為主（如 Apple、Microsoft、Nvidia），代表美國成長型與科技導向的市場區塊。

0050.TW (元大台灣卓越 50 基金)：追蹤台灣 50 指數，成份股為台灣市值最大的 50 家上市公司（如台積電、鴻海、聯發科），是台灣最具代表性的 ETF。

資料下載使用 `yfinance` 之 `download()` 方法,以 `period="10y"` 取得近十年日線資料,實際區間為 2016 年 1 月至 2026 年 1 月。每日資料欄位包含開盤價 (Open)、最高價 (High)、最低價 (Low)、收盤價 (Close)、成交量 (Volume)，以下簡稱 OHLCV。所有價格皆為還原權息後之調整收盤價，以排除股利與股票分割對價格連續性之干擾。資料定期更新與清洗則透過 `update_database.py` 腳本執行（詳見 3.2.2 節）。

3.2.2 資料清洗與時間對齊

由於美股與台股交易日曆不同,本研究取三市場交易日之交集,僅保留三者皆有交易之日期,以確保跨市場比較之時間基礎一致。資料經 `yfinance` 取得

後存入 SQLite 資料庫(etf_data.db);所取得之 OHLCV 已為還原權息後之調整價格。經檢視,三檔 ETF 於本研究期間(2016–2026)各欄位均無缺失值,故未進行插補處理。

交易日對齊

首先分別取得 SPY、QQQ 與 [0050.TW](#) 的完整交易日列表,計算三者交集,僅保留三個市場皆有交易的日期。三市場原始交易日分別為 SPY 2,514 日、QQQ 2,514 日、0050.TW 2,432 日,取交集後保留 2,350 個共同交易日。被剔除者主要為各市場獨有之假日(如美國感恩節翌日、台灣端午節與中秋節)。雖然樣本數略減,但確保了後續比較之時間基礎一致。

缺失值處理

在保留的交易日內,仍可能出現部分欄位缺失(例如 Yahoo Finance 偶爾未提供成交量)。本研究採分層處理:若僅單一欄位缺失,以前後各一交易日的線性插補填補(公式 $X_{miss} = \frac{X_{t-1} + X_{t+1}}{2}$);若整日所有欄位皆缺失(極少發生),則直接刪除該日;若連續三日以上多欄位缺失(本資料期間未發生),則刪除該區間以避免插補偏差。經檢查,三檔 ETF 在 2016–2026 年間,個別欄位缺失比例均低於 0.1%,且無連續多日缺失。

一致性驗證

處理完畢後,使用 Pandas 的 assert_series_equal() 確認三者的日期索引完全相同。最終共取得 2,350 个交易日,作為後續特徵計算與模型訓練的基礎。

3.2.3 特徵工程

特徵組合 (Feature Engineering)

各任務採用不同之特徵組合。以分類任務為例,每一交易日之特徵向量由報酬率與三項技術指標構成:

$$x_t = [Return_t, MA20_t, MA60_t, RSI_t]$$

維度為 4。樹模型迴歸則改採落後收盤價(Lag1、Lag2、Lag5)、MA10、MA50 與 10 日波動率(Vol10)共 6 維特徵;LSTM 迴歸直接以過去收盤價序列為輸入。所有特徵皆以原始數值計算,不同 ETF 之指標各自獨立計算,但採用完全相同之公式與參數,以確保跨市場比較之公平性。

移動平均線 (Moving Average, MA)

移動平均線用於平滑價格波動，反映股價的短期與長期趨勢。本研究計算兩種週期：

MA20：約一個月的平均收盤價，代表短期趨勢。計算公式為

$$MA20_t = \frac{1}{20} \sum_{i=0}^{19} Close_{t-i}。$$

MA60：約一季的平均收盤價，代表中期趨勢。計算公式同上，視窗長度改為 60。

當短期 MA 向上穿越長期 MA 時，通常被視為多頭訊號；反之則為空頭訊號。本模型不直接使用交叉訊號，而是將 MA20 與 MA60 數值同時輸入，讓模型自行學習其相對關係。

相對強弱指標 (Relative Strength Index, RSI)

RSI 衡量股價在特定週期內的上漲與下跌力道，常用於判斷超買或超賣狀態。本研究設定週期為 14 日，計算公式如下：

$$RS = \frac{\text{平均上漲幅度}}{\text{平均下跌幅度}} = \frac{\frac{1}{14} \sum_{i=1}^{14} \max(Close_{t-i+1} - Close_{t-i}, 0)}{\frac{1}{14} \sum_{i=1}^{14} \max(Close_{t-i} - Close_{t-i+1}, 0)}$$

$$RSI = 100 - \frac{100}{1 + RS}$$

RSI 值介於 0 到 100 之間。一般認為 RSI > 70 為超買區，可能面臨回調；RSI < 30 為超賣區，可能出現反彈。本模型不預設閾值規則，而是直接將 RSI 數值作為輸入特徵。

歷史波動率 (Historical Volatility)

歷史波動率（Volatility）：計算過去 20 日收盤價報酬率的標準差，並年化（乘以 $\sqrt{252}$ ）。波動率可作為市場風險的代理變數。

波動率衡量價格的變動幅度，可作為市場風險的代理變數。本研究計算 20 日報酬率的標準差，並年化以符合一般習慣：

$$Volatility_t = \sqrt{252} \times \sqrt{\frac{1}{19} \sum_{i=0}^{19} (r_{t-i} - \bar{r})^2}$$

其中 $r_t = \ln\left(\frac{Close_t}{Close_{t-1}}\right)$ 為對數報酬率， $\bar{r}$ 為 20 日平均報酬率。年化因子 $\sqrt{252}$ 代表一年約有 252 個交易日。

特徵組合

除了上述三項技術指標外，原始收盤價也保留作為特徵，因為收盤價本身的絕對水準仍含有資訊（例如股價接近歷史高點或低點）。因此，每個時間點的特徵向量為：

$$x_t = [Close_t, MA20_t, MA60_t, RSI_t, Volatility_t]$$

維度為 5。所有特徵皆以原始數值計算，不同 ETF 的指標各自獨立計算，但採用完全相同的公式與參數，以確保跨市場比較的公平性。

3.2.4 目標變數（標籤）

本研究定義的預測任務為：給定過去 30 個交易日之特徵序列，預測次日收盤價相對當日之漲跌方向。這是一個二元分類問題，標籤定義如下：

$$y_t = \begin{cases} 1, & \text{if } Close_{t+1} > Close_t \text{ (上漲)} \\ 0, & \text{otherwise (下跌或持平)} \end{cases}$$

選擇「漲跌方向」而非「精確報酬率」的原因有二：第一，對一般投資人而言，知道明天會漲還是跌，比知道漲多少更具決策參考價值；第二，方向預測的錯誤容忍度較高，且可避免回歸任務中常見的極端值干擾。持平（漲跌幅為零）的情形在資料中佔比極低（小於 0.1%），將其歸類為下跌不會顯著影

響類別平衡。

此為分類任務之標籤。迴歸任務之目標變數則為次日收盤價本身 (Close_{t+1})。

3.2.5 數據標準化

由於不同特徵之數值範圍差異甚大(例如收盤價約在數十至數百元,RSI 固定於 0 - 100 之間),若未經標準化,數值較大之特徵將主導模型之梯度更新,導致收斂緩慢甚至不穩定。本研究依不同任務採用不同之標準化方式。

分類任務採 `scikit-learn` 之 `StandardScaler` 進行 z -score 標準化,公式為:

$$z = \frac{x - \mu}{\sigma}$$

其中 μ 與 σ 分別為該特徵在訓練集上之均值與標準差,標準化後各特徵呈零均值、單位變異。

LSTM 迴歸採 `MinMaxScaler` 將特徵縮放至 $[0, 1]$ 區間,公式為:

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

其中 x_{min} 與 x_{max} 為該特徵在訓練集上之最小值與最大值。

樹模型迴歸因決策樹結構對特徵尺度不敏感,故不另行標準化。

所有縮放器之參數(均值、標準差或最大最小值)僅以訓練資料執行 `fit()`,再對測試資料執行 `transform()`,以避免「資料洩漏」(data leakage)——若以整個資料集計算縮放參數,測試資料之資訊將間接流入訓練過程,導致模型效能被高估。

3.3 預測模型介紹

本研究涵蓋四大類模型:統計模型(ARIMA)、機器學習集成模型(隨機森林、XGBoost、AdaBoost、Gradient Boosting)、深度學習模型(LSTM 系列)與大語言模型(GPT 系列),並同時用於「次日漲跌分類」與「次日收盤價迴歸」兩種任務。

3.3.1 統計基準模型 (ARIMA)

本研究以 ARIMA(自迴歸整合移動平均)作為迴歸任務之基準模型,針對各市場收盤價之單變量序列建模。實作採用 Python 之 pmdarima 套件,以 auto_arima 依 AIC 自動選定階數。為確認差分需求,先以 ADF 檢定檢驗序列定態性;結果顯示三市場原始收盤價序列之 p 值均約 0.99(非定態),故差分階數 d 均設為 1。為符合真實預測情境,測試階段採逐日滾動預測(rolling forecast):每預測一日即將該日真實值納入,更新模型後再預測次日。ARIMA 結構簡潔、可解釋性高,作為衡量複雜模型是否真能帶來效能增益之對照基準。

3.3.2 隨機森林 (Random Forest)

隨機森林由 Breiman (2001) [9]提出,是一種集成學習方法,透過建立多棵決策樹並以多數投票決定最終預測。每棵決策樹在訓練時使用「自助抽樣」(bootstrap)從原始資料中抽取不同的樣本集,並在每個節點分裂時只考慮隨機選取的一部分特徵,從而降低樹與樹之間的相關性,提升整體的泛化能力。

本研究將隨機森林作為機器學習集成模型之代表之一(與 XGBoost、AdaBoost、Gradient Boosting 並列),而非整體基準。其以當日之特徵向量為輸入,本身不具時間序列記憶能力,恰可與具記憶能力之 LSTM 形成對比,藉以凸顯時序建模之價值。

實作上使用 scikit-learn 之 RandomForestClassifier,主要超參數為決策樹

數量 100、最大深度 10。輸入為當日之特徵向量，輸出為二元分類(上漲/下跌)。

3.3.3 其他集成模型（XGBoost、AdaBoost、Gradient Boosting）

除隨機森林(Bagging)外,本研究另納入三種 Boosting 系列模型。Gradient Boosting 沿損失函數之梯度方向逐步擬合前一輪殘差;XGBoost 於其上加入正規化項與二階梯度近似,兼顧精度與效率;AdaBoost 則於每輪提高被錯分樣本之權重,使後續學習器更專注於難分樣本。此三者主要用於迴歸任務,與隨機森林共同構成集成模型之比較組。

3.3.4 單層 LSTM（Single-Layer LSTM）

單層 LSTM 是長短期記憶網路最基本的架構，僅包含一個 LSTM 隱藏層，本研究使用 TensorFlow/Keras 框架實作。其設計如下：

輸入層：接受形狀為 [batch, 30, 4] 之序列資料，其中 30 為時間步數（過去 30 天），4 為每個時間點之特徵維度（收盤價、MA20、MA60、RSI、波動率）。

LSTM 層：設定 50 個記憶單元，並設定 return_sequences=False，表示該層只輸出最後一個時間步之隱藏狀態。單元數之設定參考相關文獻（Fischer & Krauss, 2018）及實證研究結果，單元數設為 50，參考相關文獻常見設定並經初步實驗調整。

Dropout 層：在 LSTM 層之後加入比率為 0.2 之 Dropout，隨機丟棄 20% 神經元，以減少過度擬合。

輸出層：接一個全連接層（Dense）搭配 Sigmoid 激活函數，將 50 維特徵轉換為一個 0 到 1 之間的機率值，代表次日上漲之預測機率。

此架構能有效捕捉時間序列之中短期依賴關係（Fischer & Krauss, 2018）。然而，由於只有單層，它無法像雙層 LSTM 那樣提取更高層次之特徵抽象。本研究將單層 LSTM 作為比較基準，用以評估增加網路深度（雙層）是否能帶來顯著之效能提升。

3.3.5 雙層 LSTM (Double-Layer Stacked LSTM)

雙層 LSTM 是在單層 LSTM 的基礎上，堆疊第二個 LSTM 層，使模型能夠學習更高層次的时间抽象特徵。其架構設計如下：

第一層 LSTM：設定 50 個記憶單元，並將 `return_sequences=True`，表示該層會輸出每個時間步之隱藏狀態（`shape` 為 `[batch, 30, 50]`），而非僅輸出最後一個時間步，以將完整序列資訊傳遞給下一層。

Dropout 層：在第一層輸出後，加入比率為 0.2 之 Dropout，防止模型過度依賴特定特徵。

第二層 LSTM：設定 50 個記憶單元，相較第一層減少單元數，目的在於於第一層提取之特徵基礎上進行更高層次之抽象，同時降低模型複雜度以避免過度擬合，並將 `return_sequences=False`，表示該層只輸出最後一個時間步之隱藏狀態（`shape` 為 `[batch, 50]`）。此 50 維向量濃縮了過去 30 天之重要資訊。

輸出層：接一個全連接層（Dense）搭配 Sigmoid 激活函數，將 50 維特徵轉換為 0 到 1 之間之機率值。

此架構之優點在於：第一層捕捉短期價格波動模式，第二層則在第一層之基礎上提取更穩定之趨勢特徵。與單層 LSTM 相比，雙層 LSTM 通常能獲得更好之預測效能，但也更容易過度擬合，因此需搭配 Dropout 與早停法。

圖 3-2 雙層 LSTM 模型架構圖



3.3.6 單向 LSTM (Unidirectional LSTM)

單向 LSTM 是標準之 LSTM 架構，資訊只能從過去往未來流動。本研究採用之單向 LSTM 與 3.3.4 節之單層 LSTM 在結構上完全相同（50 個單元、Dropout 0.2、Sigmoid 輸出層），此處特別強調其「單向」特性，以與後續之雙向 LSTM 對照。

在預測「次日漲跌」之任務中，單向 LSTM 符合實際交易情境——當站在時間點 t 時，只能看到 t 及之前之數據，無法得知 $t+1$ 之價格。因此，單向 LSTM 之效能可視為「不使用未來資訊」之參考點。若雙向 LSTM 之效能顯著優於單向 LSTM，則表示序列內之反向讀取能幫助模型學習更穩定之模式；反之，若雙向 LSTM 表現較差，則可能是此種反向資訊引入了與真實預測情境不符之雜訊（Qiu et al., 2020）。

3.3.7 雙向 LSTM (Bidirectional LSTM)

雙向 LSTM (BiLSTM) 由兩個獨立的 LSTM 層組成：一個正向層從 $t = 1$ 到 $t = 30$ 讀取序列，另一個反向層從 $t = 30$ 到 $t = 1$ 讀取序列。兩個層的隱藏狀態在最後一個時間步被合併，使模型能同時利用過去與未來的序列資訊。

本研究使用 Keras 的 Bidirectional 包裝器，內部 LSTM 單元數設為 50，並設定 `return_sequences=False`。正向與反向各產生 50 維隱藏向量，合併後為 100 維。其後同樣接 Dropout 0.2 與 Sigmoid 輸出層。

需注意，雙向 LSTM 在訓練階段使用了輸入序列內的反向時間資訊（即從第 30 天回溯至第 1 天）。雖然這種設計在語音識別、自然語言處理等任務中已被證實有效 (Graves et al., 2013)，但在金融預測任務中，反向資訊的引入是否合理仍有爭議。因為在實際預測情境下，預測者只能使用過去 30 天的資料，無法預先看到這 30 天之後的價格變化。因此，雙向 LSTM 可能學習到與真實預測情境不符的模式。本研究將透過實驗結果 (4.1.1 節) 比較雙向 LSTM 與單向 LSTM 的效能差異，以驗證此架構是否適用於次日漲跌預測。

3.4 模型訓練與評估方法

本研究採監督式學習框架。分類任務以過去 30 個交易日之技術指標為輸入，預測次日漲跌；迴歸任務則預測次日收盤價。為確保評估真實性，資料分割嚴格依時間順序，避免未來資訊洩漏。以下依序說明分類任務之資料分割、迴歸任務之交叉驗證、超參數設定、類別不平衡處理、早停法、評估指標與模型比較策略。

A. 資料分割與驗證方式

分類任務依時間順序以 80%（訓練）對 20%（測試）切分，不另設驗證集。以 SPY 為例，特徵工程後共 2,455 筆，訓練集為 2016 年 4 月至 2024 年 1 月、測試集為 2024 年 1 月底至 2026 年 1 月。

迴歸任務則統一採時間序列交叉驗證（TimeSeriesSplit），折數設為 5，確保每折訓練集均早於測試集。相較於隨機 k 折交叉驗證，此設計可避免以未來資訊回測過去之偏誤（Hyndman & Athanasopoulos, 2021）。其中 ARIMA 於每折測試段內採逐日滾動預測，使其與樹模型、LSTM 同為單步預測情境，達成公平比較。

B. 滑動視窗與樣本生成

每個樣本包含連續 30 天之特徵（30×4），以及第 31 天之標籤；以步長 1 滑動，共產生約（總天數 - 30）個樣本，並嚴格依時間順序切割。

C. 模型超參數設定

各模型超參數設定如下表。LSTM 單元數 50、Dropout 0.2 參考相關文獻（Fischer & Krauss, 2018）及初步實驗調整；隨機森林之樹數與深度亦參考文獻設定。

表 3-1 各模型超參數設定

Model	超參數	設定值	理由
隨機森林	n_estimators / max_depth	100 / 10	參考文獻
XGBoost	n_estimators / max_depth / lr	100 / 4 / 0.1	參考文獻及初步實驗
AdaBoost / GBM	n_estimators	100	參考文獻
LSTM 變體	各層單元數	50	參考文獻、初步實驗
LSTM 變體	Dropout / 優化器	0.2 / Adam	常見設定
LSTM 變體	損失函數	分類:二元交叉熵; 迴歸:MSE	對應任務
LSTM 變體	批次 / 迭代	32 / 早停 (耐心 10)	避免過擬合

D. 類別不平衡處理

在金融時間序列中，上漲與下跌天數通常不相等，主要原因包括：樣本期間之市場整體趨勢（例如 2016 至 2026 年間美股長期多頭）、特定事件影響（如疫情後之快速反彈），以及交易日曆效應等。本研究統計三檔 ETF 於訓練期間之漲跌分佈：SPY 上漲天數佔 54.9%，QQQ 佔 56.5%，0050.TW 佔 52.0%。雖未達極度不平衡，但仍存在小幅偏差；若直接以準確率作為評估指標，模型可能偏向預測多數類別（上漲）而獲得虛高之準確率。

因此，本研究採用 F1-score 作為主要評估指標。F1-score 為精確率與召回率之調和平均，對類別不平衡較為穩健，能避免模型因偏向多數類別而產生之評估失真。此外，本研究於分類任務中另設「Always-Up」基準（即無條件預測每日皆上漲）作為對照，藉以檢驗各模型是否真正具備方向判別能力，而非僅反映市場之上漲偏態。

E. 早停法與模型儲存

本研究之 LSTM 系列模型以 Adam 優化器進行訓練，批次大小設為 32，訓練週期（epoch）為 20，損失函數於分類任務採二元交叉熵、於迴歸任務採均方誤差（MSE）。為降低隨機初始化造成之效能波動，每一深度學習模型以不同隨機種子重複訓練並取其平均表現。訓練完成後，深度學習模型以 Keras 之 `model.save()` 儲存為 .h5 檔案，樹模型則以 `joblib.dump()` 儲存為 .pkl 檔案，供後續平台載入使用。

F. 評估指標

分類任務以 F1-score 為主要評估指標，並計算精確率（Precision）、召回率（Recall）與準確率（Accuracy）作為輔助；各指標定義如下：

精確率：預測為上漲之樣本中，實際亦上漲之比例。

召回率：實際上漲之樣本中，被正確預測為上漲之比例。

F1-score：精確率與召回率之調和平均，
$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

迴歸任務則以 MAPE（可跨市場比較）為主要指標，並輔以 MSE、RMSE、MAE 與決定係數（ R^2 ）。其中 MSE 受股價尺度影響，僅適合同一市場內比較；MAPE 為百分比，可跨市場比較。

G. 模型比較策略

分類任務於各市場（SPY、QQQ、0050.TW）比較隨機森林與 LSTM 系列模型之 F1-score，並以「Always-Up」基準作為對照；迴歸任務則比較 ARIMA、四種樹模型（隨機森林、XGBoost、AdaBoost、Gradient Boosting）與單／雙層 LSTM 之 MSE 與 MAPE。深度學習模型均以不同隨機種子重複訓練取平均，以減少隨機性影響，最終選出各市場各任務之最佳模型。

3.5 LLM-ETF 系統架構及效能測試

本研究實作之系統命名為 LLM-ETF，其整體架構如圖 3-1 所示。系統分為資料處理、模型預測、視覺化呈現與 GPT 輔助摘要四個模組。

A. 系統架構與資料流

平台提供以下功能：

1. 資料來源：透過 Yahoo Finance API 下載 ETF 之 OHLCV 歷史資料（Open, High, Low, Close, Volume）。
2. 資料清洗與儲存：以 `update_database.py` 腳本進行資料爬蟲與清洗，處理缺失值與時間對齊，清洗後之資料存入 SQLite 資料庫（`etf_data.db`）。

3. 特徵工程：依預測任務計算對應特徵
分類任務計算 MA20、MA60、14 日 RSI 等技術指標並以 StandardScaler 標準化；迴歸任務則計算落後價（Lag1/2/5）、MA10、MA50 與波動率等特徵，標準化方式與各模型訓練時一致。
4. 模型預測：平台同時提供分類與迴歸兩種預測。分類載入預先訓練完成之最佳分類模型（於 4.1 節選出），輸入最近 30 天之標準化特徵，輸出次日上漲機率（0 至 1 之間之數值）；迴歸則載入最佳迴歸模型，預測次日報酬率後換算回收盤價——以報酬率建模可避免樹模型受訓練範圍上限所限而產生之外推「躺平」問題。
5. 視覺化呈現：使用 Streamlit 框架建構互動式網頁，透過 Plotly 繪製收盤價走勢圖及技術指標圖，並以儀表板方式並排顯示台股與美股之預測結果。
6. GPT 輔助摘要：呼叫 OpenAI GPT API，將當日之技術指標（RSI、MA、波動率）及模型預測結果組合成提示詞，要求 GPT 產生 30 至 50 字之風險摘要與操作建議。此模組僅作為輔助解說，並不參與價格預測。

B. 主要功能模組

平台提供以下功能：

- 標的選擇：下拉選單可選擇 SPY、QQQ 或 0050.TW。
- 即時預測：點擊「預測」按鈕後，系統自動讀取最近資料並計算技術指標，經標準化後送入預測模型。分類模型輸出次日上漲機率，並轉換為「看漲」或「看跌」之直觀文字；迴歸模型則輸出次日預測收盤價，供使用者參考價格水準之變動。
- 走勢對照圖：以 Plotly 繪製 SPY 與 0050.TW 之歷史收盤價對比圖，使用者可選取時間範圍，方便比較台股與美股之同步性。

- 技術指標顯示：顯示當前最新之 RSI、MA20、MA60 數值，並標註是否處於超買（RSI > 70）或超賣（RSI < 30）區域。
- GPT 風險摘要：根據當日指標自動生成簡短之市場風險提示與操作建議，幫助使用者理解模型輸出。

C. 使用者介面設計原則

為使預測結果易於使用者理解，本平台參考 Few（2013）提出之儀表板設計原則：

- 簡潔性：僅顯示預測結果、關鍵技術指標與走勢圖，避免資訊過載。
- 對比性：分類之上漲機率以綠色漸變條顯示、下跌以紅色漸變條顯示，迴歸之預測收盤價則以走勢圖標示於實際價格旁；台股與美股走勢圖使用不同顏色區分。
- 導航性：主要操作（選擇標的、預測按鈕）集中於左側邊欄，預測結果與圖表佔據主要區域，視線自然流動。

此外，本研究參考葉國毅（2024）之平台實作經驗，以視覺化方式輔助使用者比較台股與美股之預測差異

D. 效能測試

本研究將 LLM-ETF 平台部署於一般個人電腦環境，以確認其在無特殊硬體加速之情況下仍能順暢運作。經實際操作測試，自使用者點擊「預測」按鈕至結果與圖表呈現，整體回應時間約在一秒內，其中以圖表渲染與 GPT 摘要生成耗時較長。整體而言，平台於一般個人電腦上即可達到即時互動之設計目標，具備良好之可近用性（Few, 2013）。

第四章 研究成果與分析

本章呈現模型效能比較結果、跨市場預測難度差異、大語言模型輔助實驗以及平台效能測試，並回答第一章提出之研究問題。

4.1 模型效能比較

A. SPY 市場各模型比較

本研究首先於美國整體市場代表 ETF（SPY）進行模型效能比較，測試期間為 2024 年 1 月底至 2026 年 1 月，以 F1-score 為主要評估指標，並以「Always-Up」基準（無條件預測每日皆上漲）作為對照。各模型表現如表 4-1 所示。

表 4-1：各模型於 SPY 市場之分類效能

模型	F1-score	精確率	召回率
Always-Up 基準	0.735	—	1.000
隨機森林	0.725	0.578	0.972
單層 LSTM	0.728	0.576	0.989
雙層 LSTM	0.700	0.539	1.000
雙向 LSTM	0.689	0.566	0.881

由表 4-1 可觀察到一關鍵現象：各模型之 F1-score 均貼近 Always-Up 基準（0.735），未見任一模型顯著超越。其中雙層 LSTM 召回率達 1.0、但精確率僅 0.539，意味其近乎無條件預測「上漲」，與基準行為高度相似。此顯示，於長期多頭之測試期間，高 F1 主要來自市場本身之上漲偏態，而非模型真正掌握方向性資訊。各模型間之差距（0.689 至 0.728）甚小，亦印證此推論。此一觀察提醒：單以分類 F1 評估，易高估模型能力，此亦為本研究後

續納入迴歸任務與 MAPE 指標之主要動機。

B. QQQ 與0050.TW市場表現

為檢驗模型於不同市場之泛化能力，本研究進一步於科技股 ETF（QQQ）與台灣市場 ETF（0050.TW）進行相同比較，各市場最佳模型與基準如表 4-2 所示。

表 4-2：QQQ 與 0050.TW 市場之分類效能

市場	模型	F1-score	精確率	召回率
QQQ	Always-Up 基準	0.731	—	1.000
QQQ	隨機森林	0.732	0.588	0.972
QQQ	雙層 LSTM	0.711	0.587	0.903
0050.TW	Always-Up 基準	0.706	—	1.000
0050.TW	單層 LSTM	0.694	0.533	0.994
0050.TW	雙層 LSTM	0.691	0.527	1.000

由表 4-2 可歸納三點：第一，QQQ 市場最佳者為隨機森林（0.732），與其 Always-Up 基準（0.731）幾乎持平，再次顯示模型未能明顯超越偏態基準。第二，台灣市場（0050.TW）整體預測難度明顯高於美股，最佳模型（單層 LSTM）F1 僅 0.694，且其基準（0.706）亦低於美股，反映不同市場可預測性之本質差異（Lo, 2017）。第三，0050.TW 之雙層 LSTM 召回率達 1.0、F1 卻低於單層，同樣呈現「近乎全猜上漲」之傾向。

C. 召回率與精確率之分析

綜合 SPY 與 0050.TW 之結果可見一致現象：部分模型（尤其雙層 LSTM）召回率達 1.0、精確率卻偏低，代表其採取近乎「全部預測上漲」之策略。此策略之高 F1 並非源於有效之方向判別，而是測試期市場上漲日偏多所致；一旦市場轉為震盪或空頭，此類模型之效能將大幅下降。因此，本研究不

宣稱任一分類模型為絕對最佳，而是指出：在多頭偏態下，分類 F1 之鑑別力有限，須輔以迴歸任務方能更真實評估各模型之預測能力。

D. 跨市場預測難度差異

由 4.1 結果可見，所有模型於台股 0050.TW 之 F1-score 均低於美股。以最佳模型量化其落差：

SPY 最佳 F1：0.728（單層 LSTM）

0050.TW 最佳 F1：0.694（單層 LSTM）

落差約 0.034

此落差可能源於以下原因：

1. 市場結構差異：台股之參與者結構、流動性與產業組成與美股不同，影響價格行為之可預測性（Lo, 2017）。
2. 資訊傳播效率：美股資訊透明度與即時性較高，價格對新資訊反應更迅速。
3. 資料特性：本研究期間（2016–2026）台股交易日數較少，部分技術指標於低流動性時段可能含較多雜訊。

4.2 迴歸任務效能比較

相較於分類任務僅預測漲跌方向，迴歸任務要求模型直接預測次日收盤價之數值，更能反映模型對價格水準之掌握能力。本節比較統計模型（ARIMA）、四種集成樹模型（隨機森林、XGBoost、AdaBoost、Gradient Boosting）與單／雙層 LSTM 於三個市場之迴歸效能。所有迴歸模型均採時間序列交叉驗證

（TimeSeriesSplit，五折），ARIMA 並於每折測試段內採逐日滾動預測，以確保各模型同為單步預測之公平比較。評估指標以平均絕對百分比誤差（MAPE）為主——其為百分比，可跨市場比較；均方誤差（MSE）則因受股價尺度影響，僅供同一市場內比較。各模型之測試集 MSE 與 MAPE 如表 4-3 與表 4-4 所示，

圖 4-2 則以模型族別呈現三市場之 MAPE 比較。


表 4-3：各模型迴歸測試集 MSE

模型	SPY	QQQ	0050.TW
ARIMA	19.57	21.53	0.18
決策樹	2782.10	3362.08	45.87
隨機森林	2723.22	3142.58	35.09
XGBoost	2797.95	3291.94	37.17
AdaBoost	3398.31	3596.48	33.98
Gradient Boosting	2819.75	3277.47	35.67
單層 LSTM	125.56	200.68	1.77
雙層 LSTM	132.77	279.36	1.62

表 4-4：各模型迴歸測試集 MAPE (%)

模型	SPY	QQQ	0050.TW
ARIMA	0.79	1.04	0.87
決策樹	8.64	11.63	9.76
隨機森林	8.44	11.10	8.63
XGBoost	8.66	11.18	8.91
AdaBoost	9.80	11.88	8.52
Gradient Boosting	8.64	11.40	8.91
單層 LSTM	2.14	3.36	2.94
雙層 LSTM	2.41	3.73	3.02

圖 4-2:三市場各模型族之測試集 MAPE 比較(數值越低越佳)



由表 4-3、表 4-4 與圖 4-2 可歸納三點關鍵發現：

第一，三市場之模型排序完全一致：以 MAPE 衡量，ARIMA（0.79%~1.04%）優於 LSTM（2.14%~3.73%），再優於集成樹模型（8.44%~11.88%）。此一致性顯示該排序並非特定市場之偶然，而是模型本質能力之反映。

第二，集成樹模型誤差最大，且具結構性原因。決策樹、隨機森林等樹模型之預測值無法超出訓練資料之數值範圍，故於持續創高之測試期間，面對歷史新高價時會系統性低估，呈現「預測躺平」之現象。此為樹模型先天之外推限制，而非調參所能解決；決策樹之誤差又較隨機森林為高（如 0050.TW 之 MAPE 為 9.76% 對 8.63%），亦佐證集成之必要性。

第三，ARIMA 表現最佳。其透過一階差分（ $d=1$ ）對價格水準之變動建模，能跟隨價格趨勢、不受訓練範圍之數值上限所限，故於三市場 MAPE 均低於 1.1%。整體而言，於價格迴歸任務上，較複雜之模型未必優於較簡單之統計模型；此結果亦與吳冠霆（2025）發現 ARIMA 優於 LSTM 之結論相互呼應。

4.3 大語言模型輔助實驗

除上述傳統模型外，本研究另以 OpenAI GPT 系列模型進行兩項探索性實驗——分類任務與迴歸任務，以評估大語言模型在金融數值預測上之潛力與限制。需特別說明，此處實驗定位為概念驗證（proof of concept）：GPT 並未經過任何任務專屬訓練，僅透過提示詞（prompt）提供近期技術指標，要求其直接輸出預測。受 API 成本與速率限制，測試樣本數有限，故結果不宜與經完整訓練之傳統模型直接比較，而應視為對 LLM 能力邊界之初步探查。

A. 分類任務（GPT-3.5）

本實驗以提示詞方式，將近期技術指標（收盤價、MA20、MA60、RSI、波動率）提供予 GPT-3.5，要求其預測次日漲跌方向。測試樣本為自 2022 年起連續 200 個交易日，溫度參數（temperature）設為 0.7。結果如表 4-3 所示。

表 4-5 GPT-3.5 分類任務結果（SPY，200 樣本）

指標	數值
準確率	0.510
精確率	0.454
召回率	0.621
F1-score	0.524

觀察發現，GPT-3.5 之 F1-score 僅 0.524、準確率約 0.510，接近隨機猜測之水準。雖然 LSTM 與隨機森林之 F1 較高（約 0.69~0.73），惟該數值亦未超越 Always-Up 基準（約 0.74），高分主要源自多頭市場之上漲偏態，而非真正之方向判別能力。其混淆矩陣顯示 GPT-3.5 傾向偏向預測「上漲」，存在明顯之方向判別困難。此結果與本研究文獻探討所引

ICBBEM 2025 之發現一致：大語言模型於結構化之股價方向預測上仍面臨顯著挑戰，難以僅憑技術指標之文字描述穩定地判別漲跌。其原因可能在於，LLM 並非為數值序列之模式辨識而設計，對於缺乏明確語意之純數字輸入，難以萃取有效之預測訊號。

B. 迴歸任務（GPT-4o-mini）

相較於分類，迴歸任務要求模型直接輸出次日收盤價之數值。本實驗以 GPT-4o-mini 進行，測試樣本為三市場各自 2022 年起之 50 個交易日，評估指標採 MSE、RMSE、MAE 與決定係數（ R^2 ）。結果如表 4-4 所示。

表 4-6 GPT-4o-mini 迴歸任務結果（小樣本，各 50 筆）

市場	R^2	MSE	RMSE	MAE
SPY	0.800	43.23	6.58	5.23
QQQ	0.802	66.11	8.13	6.62
0050.TW	0.802	0.21	0.46	0.35

觀察發現，GPT-4o-mini 於三個市場之 R^2 均約達 0.80，且跨市場一致，顯示其在小樣本之數值預測上具相當潛力。值得注意的是，同一模型於迴歸任務之表現遠優於分類任務，此現象與本研究之整體發現呼應：股價之「水準」具高度連續性與慣性，次日收盤價與當日相近，模型只需掌握價格之延續趨勢即可達高 R^2 ；而「方向」（漲或跌）則屬高雜訊之二元判斷，難度顯著較高。惟本實驗樣本數僅 50 筆，且 R^2 易受價格自相關性影響而偏高，故此結果僅為探索性發現，其穩定性與泛化能力仍需更大規模之驗證。

綜合兩項實驗，大語言模型於未經專屬訓練之情況下，於數值迴歸上展現一定潛力，於方向分類上則表現有限。此結果支持本研究之定位：將 LLM 作為輔助解釋模組（生成風險摘要與白話解讀），而非取代專門設計之時序預測模型之主要引擎。

第五章 結論與建議

5.1 研究結論

本研究針對一般投資人對美股市場資訊不透明、缺乏台股與美股比較工具之問題，設計並實作了一個以大語言模型輔助之跨市場 ETF 趨勢分析平台（LLM-ETF）。透過系統性模型比較與跨市場分析，獲得以下結論，並對應第一章提出之研究問題。

研究問題回應

RQ1：在 SPY 與 QQQ 市場中，隨機森林、單層 LSTM、雙層 LSTM、單向 LSTM 與雙向 LSTM 之預測效能（F1-score）有何差異？

實驗結果顯示，分類與迴歸兩任務呈現不同樣貌。於分類任務，各模型之 F1-score 均貼近 Always-Up 基準（約 0.71~0.74），未見顯著超越者；部分模型（如雙層 LSTM）召回率達 1.0、精確率卻偏低，顯示其近乎無條件預測上漲，高分主要源於多頭市場之上漲偏態，而非真正之方向判別能力。於迴歸任務，三市場排序一致：ARIMA（MAPE < 1.1%）優於 LSTM（2%~4%）優於集成樹模型（8%~12%）。整體而言，分類任務無單一明顯冠軍，迴歸任務則以 ARIMA 最佳。

RQ2：同一預測模型在台股 0050.TW 上之效能是否顯著低於其在美股 SPY 上之效能？此差異是否反映不同市場之可預測性本質差異？

是。最佳模型於 0050.TW 之 F1 僅 0.694，低於 SPY；且迴歸任務中 0050.TW 之 MAPE 亦普遍高於美股。此落差反映台灣市場可預測性低於美國，可能源於市場結構、資訊傳播效率與交易日數差異，與適應性市場假說（Lo, 2017）一致。

RQ3：分類採 F1、迴歸採 MAPE/RMSE/R² 時,模型排序與結論是否一致？

指標選擇明顯影響結論。分類 F1 因市場上漲偏態而普遍偏高、難以分辨模型優劣；改以迴歸之 MAPE 衡量後，模型排序清晰且三市場一致。此顯示評估指標須與任務性質相符，單一指標易導致誤判，本研究因此主張價格預測宜以迴歸與尺度無關之 MAPE 為主要依據。

RQ4：一個以大語言模型輔助之視覺化平台，能否透過並排比較與簡潔圖表設計，幫助非專業使用者理解 AI 預測之結果與限制？

本研究實作之 LLM-ETF 平台提供台股與美股並排走勢圖、即時漲跌機率、技術指標數值與 GPT 風險摘要，於一般個人電腦環境下回應時間約在一秒內，可滿足即時互動需求。透過簡潔之並排設計與白話摘要，平台有助於降低非專業使用者對 AI 預測之「黑箱」疑慮，符合本研究「輔助型平台」之定位。

5.2 研究建議

基於上述結論，本研究提出以下實務與學術建議。

A. 實務建議

1. 優先採用迴歸預測而非單純分類：本研究發現，分類任務中各模型之高 F1 主要來自多頭市場之上漲偏態（召回率近 1.0 但精確率偏低），一旦市場轉向其效能即不穩定，且無法提供漲跌幅度。反觀迴歸任務，ARIMA 等模型能穩定預測次日價位（MAPE < 1.1%）。建議實務上優先採迴歸預測，以獲得更具經濟意義且更穩健之輸出。
2. LLM 在數值預測上展現潛力：本研究以 GPT-4o-mini 於三市場進行小樣本迴歸預測，得到 R²=0.80 之結果，顯示大語言模型在技術指標數值預測上具有發展空間。建議未來可擴大樣本驗證，並嘗試將 LLM 整合為主要迴歸預測

引擎之一。

3. 傳統模型可作為 LLM 之對照基準：隨機森林與 LSTM 在分類任務上表現穩定，可作為評估 LLM 數值預測能力之基準。實務上可採用集成策略，結合傳統模型之結構化學習能力與 LLM 之非結構化資訊處理優勢。
4. 複雜模型未必優於簡單模型：本研究中 ARIMA 於迴歸任務全面領先集成樹模型，後者因無法外推超出訓練範圍之新高價而系統性低估。實務上選模型時不應預設「越複雜越準」，應以簡單統計模型為基準，確認複雜模型確有增益後再採用。

B. 學術建議

1. 明確區分任務類型與評估指標：股票預測分為分類（漲跌方向）與迴歸（價格數值）兩類，適用指標不同。本研究於分類採 F1-score、於迴歸採 MAPE（可跨市場比較）為主，輔以 R^2 、MAE、RMSE。研究中更發現，同一批模型在分類 F1 下難分優劣，改以迴歸 MAPE 衡量後排序才清晰，顯示指標選擇會直接影響結論；建議後續研究依任務性質審慎選用指標，避免因單一指標而誤判模型能力。
2. 跨市場比較應考量市場結構差異：本研究發現台股 0050.TW 之可預測性顯著低於美股 SPY，此差異可能來自市場流動性、參與者結構及資訊傳播效率。建議後續研究在進行跨市場模型遷移時，納入這些控制變數。
3. LLM 在金融預測上宜採「輔助為主、預測為輔」之策略：雖然 LLM 在小樣本迴歸上表現亮眼，但其分類效能遠低於傳統模型，且對提示詞敏感。短期內宜將 LLM 定位為輔助解釋工具（如風險摘要生成），長期則需大規模驗證其數值預測之穩定性。
4. 重視簡單模型作為基準之價值：本研究發現 ARIMA 於迴歸任務全面優於集成樹模型與部分深度模型，顯示在價格預測上，結構簡潔之統計模型可能比複雜模型更穩健。建議後續研究將簡單統計模型（如 ARIMA、隨機漫步）列為必要基準，確認複雜模型確有顯著增益後再採用，以避免「為複雜而複雜」。

5.3 未來研究方向

根據本研究之限制與實驗發現，提出以下未來可延伸之方向：

1. 擴大 LLM 迴歸預測之樣本與模型比較

本研究以 GPT-4o-mini 進行次日收盤價預測，雖於三市場各 50 個樣本上取得 $R^2 \approx 0.80$ 之初步成果，惟樣本數有限，結果仍需更大規模驗證。未來可將測試樣本擴增至完整測試集，並比較多種 LLM（如 GPT-4o、Gemini 1.5 Pro、Claude 3.5）於相同迴歸任務上之效能差異，以評估 LLM 是否可作為數值預測之可靠引擎。

2. 導入總體經濟指標與新聞情緒分析

本研究僅使用價格與成交量等技術面數據，未納入總體經濟指標（如利率、VIX 指數、就業數據）與非結構化資訊（如新聞標題、社群媒體輿情）。未來可透過 FinBERT 或 LLM 本身進行情緒分數計算，結合技術指標形成多模態輸入，觀察是否能提升台股（0050.TW）之預測效能。

3. 模型融合與即時交易系統開發

本研究中不同模型於不同市場與任務各有優勢（如 ARIMA 於迴歸最佳、隨機森林於部分分類市場較穩），未來可透過加權投票或堆疊（stacking）策略加以融合，兼取統計模型之穩健性與深度模型之非線性學習能力。此外，可將批次更新架構改為即時串流（如 Apache Kafka、Redis），實現盤中即時預測與風險提示。

4. 擴充至更多市場與資產類別

本研究僅涵蓋美股（SPY、QQQ）與台股（0050.TW），未來可將框架應用至其他新興市場（如中國、東南亞）或不同資產類別（如債券 ETF、外匯、原物料），驗證跨市場泛化能力之普遍性。

5. 深化 LLM 輔助功能與使用者研究

目前平台之 GPT 摘要僅依賴技術指標數值，未來可整合即時新聞事件，讓 LLM 產生更具上下文之風險分析。同時，應進行大規模使用者實驗（如 SUS 系統易用性量表、任務完成率測試），量化評估平台對非專業使用者決策信心與理解度之影響。



全文總結

本研究以「LLM-ETF：基於大語言模型輔助之跨市場 ETF 趨勢預測與模型比較研究」為題，系統性比較了統計（ARIMA）、機器學習集成（隨機森林、XGBoost、AdaBoost、Gradient Boosting）、深度學習（單／雙層 LSTM）與大語言模型（GPT）四個世代之模型，於美股（SPY、QQQ）與台股（0050.TW）之「次日漲跌分類」與「次日收盤價迴歸」兩任務上之效能，並實作了一個以大語言模型輔助之互動式視覺化平台。

主要實驗結果顯示：於分類任務，各模型之 F1-score 多貼近「Always-Up」基準（約 0.71~0.74），高分主要來自多頭市場之上漲偏態，而非真正之方向判別能力；台股 0050.TW 之預測難度顯著高於美股。於迴歸任務，三市場排序一致——ARIMA（MAPE < 1.1%）優於 LSTM（2%~4%）優於集成樹模型（8%~12%），顯示在價格預測上較簡單之統計模型反而較複雜模型穩定；集成模型因無法外推超出訓練範圍之新高價，於持續上漲之測試期誤差最大。此外，GPT-4o-mini 於三市場小樣本迴歸均取得 $R^2 \approx 0.80$ ，展現大語言模型於數值預測上之潛力。平台於一般個人電腦環境下回應時間約在一秒內，可滿足即時互動需求。

本研究之主要貢獻在於：（1）建立涵蓋統計、機器學習、深度學習與大語言模型之跨世代、雙任務比較基準；（2）揭示台股與美股在可預測性上之顯著落差，並指出集成模型無法外推之結構性限制，論證「複雜模型未必優於簡單模型」；（3）實作一個具教學意圖之開源平台，幫助非專業使用者透過視覺化比較建立對市場運作之基本認識，從而降低因資訊不透明而產生之投資疑慮。

參考文獻

- [1] ETFGI. (2024). Global ETF assets reached \$12 trillion at the end of 2024. Retrieved from <https://etfgi.com>
- [2] Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2), 383-417.
- [3] Shiller, R. J. (2015). *Irrational Exuberance: Revised and Expanded Third Edition*. Princeton University Press.
- [4] Lo, A. W. (2017). *Adaptive Markets: Financial Evolution at the Speed of Thought*. Princeton University Press.
- [5] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785-794).
- [6] Krauss, C., Do, X. A., & Huck, N. (2017). Deep neural networks, gradient-boosted trees, random forests: Statistical arbitrage on the S&P 500. *European Journal of Operational Research*, 259(2), 689-702.
- [7] Fischer, T., & Krauss, C. (2018). Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, 270(2), 654-669.
- [8] Nabipour, M., Nayyeri, P., Jabani, H., Mosavi, A., & Salwana, E. (2020). Deep learning for stock market prediction. *Entropy*, 22(8), 840.
- [9] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32.
- [10] Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735-1780.
- [11] Zhang, D., Kabuka, M., & Chen, S. (2019). Stock market prediction using deep learning. *IEEE Access*, 7, 146986-147000.

- [12] 林子哲 (2024)。以 LSTM、Bi-LSTM 及 Transformer 模型預測台股股價準確度的研究〔碩士論文，國立成功大學〕。臺灣博碩士論文知識加值系統。取自 <https://hdl.handle.net/11296/t462nc>
- [13] Graves, A., Mohamed, A. R., & Hinton, G. (2013). Speech recognition with deep recurrent neural networks. In 2013 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP) (pp. 6645-6649).
- [14] Qiu, Y., Yang, Z., & Wang, Y. (2020). A novel stock forecasting model based on Bi-directional long short-term memory network. IEEE Access, 8, 145678-145690.
- [15] 葉國毅 (2024)。使用多頭注意力機制的多重輸入 LSTM 股價預測模型〔碩士論文，國立政治大學〕。取自 https://ah.lib.nccu.edu.tw/item?item_id=169765
- [16] Few, S. (2013). Information Dashboard Design: Displaying Data for At-a-Glance Monitoring (2nd ed.). Analytics Press.
- [17] Streamlit. (2025). Streamlit documentation. Retrieved from <https://docs.streamlit.io/>
- [18] Plotly. (2024). Plotly Python graphing library. Retrieved from <https://plotly.com/python/>
- [19] Liu, W. C. (2018). T-Brain AI competition: ETF price prediction. National Chengchi University / Taiwan AI Academy.
- [20] Bolton, P., & Kacperczyk, M. (2021). Do investors care about carbon risk? Journal of Financial Economics, 142(2), 517-549.
- [21] Hyndman, R. J., & Athanasopoulos, G. (2021). Forecasting: Principles and Practice (3rd ed.). OTexts. <https://otexts.com/fpp3/>
- [22] Box, G. E. P., & Jenkins, G. M. (1976). Time Series Analysis: Forecasting and Control. Holden-Day.
- [23] Malkiel, B. G. (1973). A Random Walk Down Wall Street. W. W. Norton & Company.

[24] 徐維延（2019）。〔論文題目〕〔碩士論文，○○大學〕。臺灣博碩士論文知識加值系統。

[25] 吳冠霆（2025）。〔論文題目〕〔碩士論文，○○大學〕。臺灣博碩士論文知識加值系統。

