

LLM-ETF：

基於大語言模型輔助之跨市場 ETF 趨勢預測與模型比較研究

Graduate School of Information Engineering
Kun Shan University

研究生：林子瑜

Tzu-Yu Lin

指導教授：李冠榮 副教授

Kuan-Rong Lee

JUN, 2026

| 簡報大綱 Agenda



前言

背景、動機與研究問題



分析主題

分類問題與迴歸問題



模型介紹

跨世代模型架構分析



研究流程

數據處理與實驗設計



實驗結果

跨市場表現評估指標



結論

關鍵發現與未來方向


研究背景與動機 不同模型與技術 == > 股票分析

資訊不對稱


- 缺乏直觀同步預測工具
- 跨市場數據處理複雜度高

AI 潛力

- 深度學習模型「黑箱」問題
- 提升模型預測可理解度



研究目的與問題



- 效能比較：統計（ARIMA）、機器學習（隨機森林等）、深度學習（LSTM）與大語言模型（LLM）在 ETF 預測之優劣
- 市場差異：分析 台股(0050)與美股 (SPY/QQQ)之預測難度差異
- 評估指標：MAPE（平均絕對百分比誤差）
- 由實作應用：建構 LLM 輔助視覺化平台，提升預測理解度

分析主題1：分類問題 (Classification)

目標與任務

預測次日收盤價相對於當日是「上漲」或「下跌」，
定義為二元分類任務。

$$y_t = \begin{cases} 1 & \text{if Price}_{t+1} > \text{Price}_t \\ 0 & \text{otherwise} \end{cases}$$

AI 預測趨勢

看漲 

↑ R²: 0.92

AI 預測趨勢

看跌 

↑ R²: -2.11

統計模型：ARIMA

- ARIMA(自迴歸整合移動平均)是時間序列預測中最常用的統計模型,本研究作為**基準模型(Baseline)**。對單變量時間序列進行建模與預測。

AR

(自迴歸,p)

假設當前值是過去 **p** 期數值的線性組合。

例:AR(1) 代表今天的值主要受昨天影響。

I

(差分整合,d)

對原始序列做 **d** 次差分,消除趨勢與單位根,讓序列變成定態

(均值與變異不隨時間漂移)。

這是 **ARIMA** 相較於 **ARMA** 的關鍵擴充。

MA

(移動平均,q)

用過去 **q** 期的預測誤差(殘差) 修正當期預測,捕捉短期衝擊的影響。

本研究三市場最佳參數 (經 ADF 定態檢定確認須差分, auto_arima 自動選定)

SPY : ARIMA(0,1,2)

QQQ : ARIMA(1,1,0)

0050.TW : ARIMA(0,1,0)

機器學習：集成迴歸模型



Random Forest

Bagging 架構，多棵樹平均降低變異數，穩定且不易過擬合。



XGBoost

Boosting 經典模型，含正規化項抑制過擬合，速度快、精度高。



AdaBoost

逐輪提高前一輪誤差較大樣本的權重，串聯弱學習器。




Gradient Boosting

沿損失函數梯度方向逐步擬合殘差，降低偏差。

Random Forest : Bagging 集成學習

從訓練資料隨機抽取多個子集，各自建立決策樹，再整合結果



Bagging (裝袋法)

對訓練資料做隨機抽樣(Bootstrap)，產生多個子集，各自訓練一棵樹。

降低變異數

多棵獨立的樹取平均(或多數決)，抵消個別樹的過擬合，模型更穩定。

整合決策

分類用多數決、迴歸取平均，結果優於單一決策樹。

本研究角色

作為機器學習(ML)代表模型，與統計、深度學習、LLM 比較。


決策樹 vs 隨機森林對照表

比較項目	決策樹	隨機森林
模型性質	單一模型	多模型集成
穩定性	容易過擬合	較穩定、泛化好
訓練方式	單棵樹	多棵樹隨機訓練
可解釋性	高	較低
準確度	中等	通常較高
計算成本	低	高(需訓練多棵樹)

隨機森林在 **Bagging** 基礎上，
額外的特徵選擇引入隨機性
(每次分裂隨機選部分特徵)

XGBoost (極限梯度提升)

Boosting 經典模型，含正規化抑制過擬合，速度快、精度高



以 **GBM** 為基礎

同樣用 Boosting 擬合殘差，但做了多項工程強化。

正規化抑制過擬合

目標函數加入正規化項(L1/L2)，控制複雜度。

速度與精度

採二階梯度近似與平行運算，訓練快、預測準。

★ 本研究角色

機器學習(ML)集成模型之一，與 RF/AdaBoost/GBM 比較。

AdaBoost (適應性提升)

逐輪提高「被分錯樣本」的權重，讓下一輪更專注難分的樣本

第1輪



第2輪



第3輪



紅色=被分錯、權重變大 藍色=正確

樣本權重隨輪次變化

樣本加權

每一輪結束後，提高「被分錯的樣本」權重，下一輪更專注它們。

串聯弱學習器


串聯多個簡單模型(通常是淺決策樹)，逐步補強。

加權

最終依各學習器表現加權整合結果。

Gradient Boosting (梯度提升)

沿損失函數梯度方向，逐步擬合殘差以降低偏差



每一輪把剩下的誤差(殘差)再擬合一次 → 越來越小

殘差逐步縮小

擬合殘差

每個新模型專門預測前面模型剩下的誤差(殘差)。

梯度下降

沿損失函數梯度方向逐步優化，降低偏差。

逐步降低偏差

弱學習器累加，整體誤差越來越小。

循環神經網路 (Recurrent Neural Network, RNN)

處理序列資料的深度學習模型，是 LSTM 的前身

RNN

專門處理序列資料(Sequential Data)的深度學習模型。

循環連結 = 記憶


神經元之間存在「循環連結」，能保留過去資訊的「記憶」，這是與前饋神經網路最大的不同。

訓練方式

透過時間的反向傳播 Backpropagation Through Time (BPTT)。

長期依賴問題

標準 RNN 難以記住長期資訊(梯度消失) → 因此發展出 LSTM、GRU。



家族演進

RNN → LSTM → GRU

(逐步解決長期依賴與梯度消失問題)


長短期記憶網路（Long Short-Term Memory, LSTM）

透過細胞狀態與三個閘門，記住長期依賴、解決傳統 RNN 的梯度消失問題

核心結構：細胞狀態（Cell State）

- LSTM 的關鍵在於細胞狀態，可想像成一條貫穿所有單元的「傳送帶」，資訊在上面流動而保持不變。LSTM 透過三個閘門精細控制這條傳送帶上的資訊增減。
- **遺忘閘門**（Forget Gate）：用 Sigmoid 決定丟棄哪些
- **資訊輸入閘門**（Input Gate）：決定哪些新資訊要寫入
- **胞狀態輸出閘門**（Output Gate）：依細胞狀態決定輸出，成為下一時點的隱藏狀態 h_t

股價為典型時間序列，LSTM 能捕捉長短期價格依賴，且端到端學習、不需手動特徵工程。



LSTM 結構圖 — 符號對照

輸入 (Inputs)

- x_t 輸入向量
- C_{t-1} 前一區塊的記憶
- h_{t-1} 前一區塊的輸出

偏置 (Bias)

- 0 每個閘門的偏置項 (0,1,2,3)

輸出 (Outputs)

- C_t 當前區塊的記憶
- h_t 當前區塊的輸出

非線性 (Nonlinearities)

- σ Sigmoid (壓縮到 0~1, 當閘門)
- $\tanh$ 雙曲正切 tanh (壓縮到 -1~1)


向量運算 (Vector operations)

- $\times$ 逐元素相乘 (element-wise $\times$)
- $+$ 相加 / 串接 (+)

各式各樣的 LSTM：單向 vs 雙向


依資訊流動方向，LSTM 可分為單向與雙向兩種

單向 LSTM (Unidirectional)



只看過去 → 現在（順時間）

雙向 LSTM (Bidirectional)



同時看過去與未來（雙向）

單向 LSTM

只用「過去」資訊預測未來，
符合真實預測情境（不偷看未來）。

本研究分為單層、雙層兩種。

雙向 LSTM (BiLSTM)

同時讀取前後文資訊。用於預測「未來」時等於偷看未來，
造成資訊洩漏——這正是本研究中 BiLSTM 表現最差的原因。

LLM 分類任務：GPT-3.5-turbo（預測次日漲跌）

以提示詞讓 GPT-3.5 預測「上漲 / 下跌」，SPY 共 200 筆

0.48

F1-score

0.47

Accuracy

0.42

Precision

0.56

Recall

結果不如傳統模型

F1 僅 0.48，明顯低於 RF/LSTM 的 0.69~0.73。


分類非 LLM 強項

GPT-3.5 以文字推理漲跌方向，缺乏穩定的數值判斷依據。

對比：LLM 迴歸表現佳

同一 LLM 改做數值迴歸(GPT-4o-mini)， R^2 達 0.80 —— 顯示 LLM 較擅長「數值預測」而非「漲跌分類」。

機器學習的標準流程 (Machine Learning Pipeline)



1. 資料收集

蒐集原始資料(資料庫、API 等)，資料品質直接影響表現。

2. 資料前處理

清理資料、處理缺失值；特徵工程(標準化、編碼)；切分訓練/驗證/測試集。

3. 模型選擇

分類: 邏輯迴歸、決策樹、隨機森林、SVM、神經網路。
迴歸: 線性迴歸、Ridge、Lasso、XGBoost。

4. 模型訓練

用訓練集學習，調整超參數，並以交叉驗證(Cross-Validation)評估穩定度。

5. 模型評估

分類: Accuracy、Precision、Recall、F1-score、ROC-AUC。
迴歸: MSE、RMSE、MAE、 R^2 、MAPE。

6. 模型調整

以超參數調整(Grid Search、貝葉斯優化)或特徵工程改進效能。

7. 部署與監控

部署至實際系統(API、雲端)；持續監控、避免概念漂移(Concept Drift)。

本研究實驗流程：對應 ML Pipeline 的實作

資料前處理

清洗、缺失值處理
→ 存入 etf_data.db

模型訓練

RF/LSTM : TimeSeriesSplit
ARIMA : rolling forecast

資料來源

Yahoo Finance API
(update_database.py)

特徵工程

Lag/MA/Vol

性能評估

MSE/MAPE/F1


實驗設計：資料集與特徵

類型	細節描述
預測標的	SPY (美股大盤), QQQ (科技股), 0050.TW (台股)
資料期間	2016 – 2026 (日級別資料)
原始特徵	OHLCV (開、高、低、收、量)
技術指標	MA20, MA60, RSI(14), 年化波動率(20)
交叉驗證	TimeSeriesSplit 時間序列交叉驗證，確保訓練集早於測試集

迴歸另採落後價 (Lag1/2/5) 與 MA10/MA50、波動率特徵

分類問題結果 (SPY/QQQ/0050.TW))

SPY 各模型分類 F1-score 比較 (含 Always-Up 基準)




觀察：四個模型 F1 均貼近或低於 Always-Up 基準 (0.736)，顯示分類的高分主要來自多頭市場的上漲偏態；雙向 LSTM 因引入未來資訊反而最差。

QQQ 各模型分類 F1-score 比較 (含 Always-Up 基準)



0050.TW 各模型分類 F1-score 比較 (含 Always-Up 基準)



迴歸結果：各模型誤差比較（MSE / MAPE）

模型	SPY 測試 MSE	QQQ 測試 MSE	0050 測試 MSE
ARIMA	31.86	40.07	0.51
Random Forest	2725.00	3137.76	35.11
XGBoost	2797.95	3291.94	37.17
AdaBoost	3398.31	3596.48	33.98
Gradient Boosting	2821.29	3277.47	35.67
單層 LSTM	125.56	200.68	1.77
雙層 LSTM	132.77	279.36	1.62

模型	SPY MAPE	QQQ MAPE	0050 MAPE
ARIMA	0.66%	0.89%	1.07%
Random Forest	8.44%	11.09%	8.63%
XGBoost	8.66%	11.18%	8.91%
AdaBoost	9.80%	11.88%	8.52%
Gradient Boosting	8.66%	11.40%	8.90%
單層 LSTM	2.14%	3.36%	2.94%
雙層 LSTM	2.41%	3.73%	3.02%


※ **MSE** 受股價尺度影響，僅供同市場內比較；**MAPE** 為百分比，可跨市場比較。
※ 同市場內排序一致：**ARIMA** < **LSTM** < 集成模型（誤差越小越佳）。

迴歸結果:預測曲線比較

QQQ 次日收盤價：實際 vs 各模型預測



SPY 次日收盤價：實際 vs 各模型預測



0050.TW 次日收盤價：實際 vs 各模型預測




※ 綠線(ARIMA)幾乎貼合實際值；
橘線(Random Forest)無法外推、預測躺平；
藍線(LSTM)能跟上趨勢但略有落差。

迴歸結果：GPT-4o-mini效能(SPY/QQQ)


市場	R ²	MSE	RMSE	MAE
SPY	0.800	43.23	6.58	5.23
QQQ	0.802	66.11	8.13	6.62
0050	0.802	0.21	0.46	0.35

GPT-4o-mini 在 SPY、QQQ 各 50 個交易日的小樣本上預測次日收盤價，R² 皆達 0.80。藍線為實際、紅線為預測，趨勢貼合度高。

GPT-4o-mini 次日收盤價預測 — SPY (小樣本 50 個交易日)




GPT-4o-mini 次日收盤價預測 — QQQ (小樣本 50 個交易日)



迴歸結果：GPT-4o-mini效能(0050.tw)

GPT-4o-mini 次日收盤價預測 — 0050.TW (小樣本 50 個交易日)



- 一、模型排序一致：ARIMA < LSTM < 集成模型
以 MAPE (跨市場可比) 衡量，三個市場排序一致：
ARIMA (0.7~1.1%) 優於 LSTM (2~4%) 優於樹模型 (8~11%)。
顯示在價格預測上，較簡單的統計模型反而比複雜模型穩定。
- 二、集成模型的限制：無法外推
集成模型(RF/XGBoost等)無法預測超出訓練範圍的新高價，
在長期上漲的測試期誤差最大，這是其結構限制而非調參問題。
- 三、LLM 展現潛力：三市場 R^2 一致達 0.80
GPT-4o-mini 在小樣本(50天)下，SPY/QQQ/0050 的 R^2 皆約 0.80，
無需訓練、僅靠提示即可達此水準，顯示 LLM 在數值預測上的潛力。

→ 綜合而言：價格預測上「複雜模型不一定優於簡單模型」；
LLM 雖為小樣本探索，但跨市場一致性高，值得後續擴大驗證。

LLM-ETF 平台實作

</> Streamlit + Plotly + SQLite

💬 GPT-3.5 / Gemini API 即時風險摘要

⚡ 平均延遲：**840 毫秒**

本平台整合預測結果與 LLM 摘要，介面輕量、一般設備即可順暢執行，適合作為教學示範與個人投資研究的輔助參考工具。



結論：分類與迴歸之抉擇

本研究兩種任務皆做，各回答不同問題

分類任務（預測漲跌方向）

- 預測次日「上漲 / 下跌」
- 最佳：RF 0.732 / 單層LSTM 0.694
- 但各模型 F1 多貼近 Always-Up 基準
- 高分主要來自多頭期間的市場偏態
- LLM(GPT-3.5) F1 僅 0.48

→ 方向看似可分，實則貼近基準

迴歸任務（預測收盤價）

- 預測次日「收盤價」數值
- ARIMA 最佳(MAPE <1.1%)
- 排序：ARIMA < LSTM < 集成模型
- 集成模型無法外推、誤差最大- LLM(GPT-4o-mini) 三市場 $R^2 \approx 0.80$

→ 數值可預測，但複雜模型未必較佳

三大關鍵發現

無單一冠軍：不同市場、不同任務，最佳模型各異

價格 R^2 高但輸基準：次日走勢難預測，分類與

LLM 為輔助 LLM 定位：適合作為「解釋型」輔助，而非純算力引擎

結論與未來研究方向

本研究貢獻

- 建立跨市場(台/美)預測基準比較。
- 揭示台股受國際連動影響之預測難點。
- 實作 LLM 輔助開源平台。

未來展望

- 導入新聞情緒與總經指標分析。
- 開發 LSTM-ARIMA 混合模型。
- 進行正式使用者 SUS 量表研究。
- 擴大 LLM 迴歸樣本至完整測試集
- 比較多種 LLM (Gemini 、 Llama 、 Gemma)

簡報結束，敬請指導